

空间 CRISPR 筛选中非细胞自主扰动效应的因果识别

基于嵌入匹配的空间 Durbin 模型

徐正昊

2026 年 8 月 1 日

大纲

① 研究动机

② 方法

③ 结果

④ 讨论

当前 SPAC-seq 分析的问题


标准流程：同心环 + 指数衰减 + 标签置换检验。

三个核心问题：

- ① 不可证伪：没有“无传播”的零假设模型；任何非零 λ 都可报告。
- ② 存在混杂：表观衰减长度混合了扰动生物学与组织结构梯度。
- ③ 单一尺度：强制一个长度尺度，遗漏多模态传播。

我们需要：因果识别 + 跨队列复现。

v1 (PerturbGNN 初版) 有 79% 假阳性




在 subQ-1 (队列 2) 上:

- v1 报告 81 个显著对
- 其中 64 个 (79%) v2 不显著
- v2 额外发现 20 个 (v1 遗漏)
- 两者共同确认仅 17 个

根因: NTC 非真零假设; z-score 无法解决空间自相关。

五层因果推断流程

PerturbGNN v2 — Embedding-matched causal propagation framework



*Replaces v1's vs-NTC PDR ≠ concentric ring ≠ exponential decay
with causal identification + sensitivity analysis*

层 1: 监督式跨模态 GNN 编码器

每个 spot 的两个视图 (K=15 邻居):


- 视图 1: 邻域表达 PCA (32 维)
- 视图 2: 邻域细胞类型组成 (8 维)

共享分类头: cell_type + niche 分类器 + 软对齐。

关键性质

source vs NTC 质心余弦相似度 = **0.9997**

⇒ 扰动信号不会泄漏到嵌入中



层 3: 多源空间 Durbin 模型

暴露场 (剂量响应, 非"半径"):

$$E_i = \sum_c M_c \cdot \exp\left(-\frac{d_{\text{res}}(i, c)^2}{2\lambda^2}\right)$$

阻力距离 d_{res} : 整合组织屏障 (细胞类型不连续性、血管邻近性)。

回归模型:


$$Y_i = \alpha + \beta \cdot T_i + \delta \cdot E_i + \gamma \cdot X_i + \varepsilon_i$$

按 clone_id 聚类稳健标准误。 λ 网格: $\{30, 60, 100, 150\} \mu\text{m}$ 。

层 4：三重因果诊断


- ① **空间 DiD**: $(Y_{\text{扰动, 近}} - Y_{\text{扰动, 远}}) - (Y_{\text{对照, 近}} - Y_{\text{对照, 远}})$
控制邻域梯度效应。
- ② **Guide-IV (两阶段最小二乘)**: 工具变量 = guide UMI 密度。
若 $\beta_{\text{IV}} \approx \beta_{\text{OLS}}$: 与因果一致。
- ③ **Rosenbaum Γ^*** : 翻转 $p > 0.05$ 所需的最小隐藏混杂强度。
 $\Gamma^* \geq 1.5$ = 中等稳健, $\Gamma^* > 3$ = 强稳健。

数据：2 个队列，8 个切片，416 万 bins



跨队列复现：7 个命中，Phgr1 占主导

Cross-cohort Durbin δ replication heatmap (★ = cross-cohort replicated)
*** $p < 0.001$, ** $p < 0.01$, * $p < 0.05$



7 个跨队列复现对

基因	响应	切片数	δ	q 值	队列
Phgr1	fibroblast	7	+0.43	3e-60	c1+c2
Phgr1	macrophage	7	+0.41	1e-41	c1+c2
Phgr1	hypoxia	7	+0.44	6e-21	c1+c2
Phgr1	endothelial	7	-0.24	2e-19	c1+c2
Rab8a	malignant	6	+0.49	5e-56	c1+c2
Bcam	malignant	6	+0.47	4e-11	c1+c2
Blnk	fibroblast	6	+0.29	8e-6	c1+c2





Phgr1: 4/7 个响应跨 7 个切片复现。

Rab8a: perturbradius 教程基因，独立验证。

Blnk: v1 的核心发现，仅 fibroblast 存活（非 macrophage）。

Phgr1 案例研究：三重因果诊断


Phgr1 case study — v2 causal diagnostics (M001 + M002)




Phgr1 TCGA LUAD 验证 (n=516)

Phgr1: triple-evidence for multi-response NCA causal hub


(a) SPAC-seq: Phgr1 δ per response
(cross-cohort direction consistency)





(b) TCGA LUAD (n=516): PHGR1 marker correlations



(c) Survival: Phgr1 high vs low
log-rank p=0.001723, Cox HR=0.59




TCGA 标记物相关 + 生存分析



PHGR1 ↔ IRF1 $\rho=+0.473$ ($p=3e-30$) | Cox HR=0.556 ($p=0.004$) | OS 22.7 vs 20.0 月

合成基准测试：统计功效校准

Synthetic benchmark: v2 pipeline recovery + power calibration



最小可检测效应 ≈ 0.05 (80% 功效, 50 个克隆)。Phgr1 $\delta=0.43 \gg$ 阈值。

Phgr1 vs v1 的 Blnk: 正面比较

维度	Phgr1 (v2)	Blnk (v1)
跨队列切片数	7	1
显著响应数	5	1
TCGA 最大 ρ	0.473	0.420
Cox HR	0.556	0.744
ICB 预测	无	无

Blnk 是单队列假象。 仅 Blnk→fibroblast 跨队列复现 ($\delta=+0.29$, $q=8e-6$)。

诚实的阴性结果

- **Phgr1 不预测 ICB 响应**

IMvigor210 (膀胱癌): $p=0.52$; 4 个黑色素瘤队列: $p=0.10-0.83$

⇒ Phgr1 标记免疫炎性微环境, 但非免疫检查点治疗的限速靶点。

- **Bcam: 大效应但预后相反**

$\delta=+0.47$ (强) 但 Cox HR=1.32 (风险因子)

⇒ 效应大 $\neq$ 临床获益。

- **Utrn: 跨队列复现但 TCGA 沉默**

UTRN 在 LUAD 中几乎不表达; 无临床相关。

局限性

- ① 队列 1 单 guide ——队列 2 有 2 guides/基因，部分缓解。
- ② 基因 panel 部分重叠——Phgr1/Utrn/Cttn 两队列均有；Rab8a/Bcam 仅队列 2。
- ③ 阻力距离为近似——路径采样，非精确电路计算。
- ④ TCGA 验证为相关性——回补实验留待未来。
- ⑤ Phgr1 ICB 阴性——如实报告。

总结

我们做了什么

五层因果框架 (GNN + 匹配 + Durbin + DiD/IV/ Γ^*) 应用于 8 个 SPAC-seq 切片、2 个队列。

我们发现了什么

Phgr1 ——多响应 NCA hub, 4 个响应 $\times$ 7 切片 $\times$ 2 队列 ($q < 1e-19$)。TCGA Cox HR=0.556。小鼠 $\rightarrow$ 人类一致。

为什么重要

跨队列复现 + 因果诊断 = 可证伪的逐基因 claim, 替代不可证伪的“传播半径”。

- **代码**: `perturbgnn_v2/` (22 张图, 完整流程)
- **论文 PDF**: 8 页, `figures/paper.pdf`
- **数据**: SPAC-seq 档案 (`spac.pku-genomics.org`)
- **TCGA**: cBioPortal (`luad_tcga_gdc`, $n=516$)
- **可复现性**: 完整流程 < 3 小时 ($1 \times V100$)

谢谢

欢迎提问